

## Deep Learning

### Laboratorio 8

Repo parte 1: <https://github.com/Arthurs101/UVG-DEEP-LEARNING-S10-LAB8>

1. ¿Cuál es el problema del gradiente de fuga en las redes LSTM y cómo afecta la efectividad de LSTM para el pronóstico de series temporales?

El gradiente de fuga se produce cuando los gradientes, los cuales sirven para modificar los pesos de la red durante el entrenamiento, se vuelven pequeños en las capas profundas de redes recurrentes, como las LSTM. Esto provoca que los cambios en los pesos sean insignificantes, restringiendo la habilidad de la red para aprender patrones a largo plazo. Pese a que las LSTM fueron creadas para disminuir este problema mediante las celdas de memoria y las puertas de entrada, olvido y salida, no están totalmente protegidas de él. Dentro del ámbito del pronóstico de series temporales, este problema puede disminuir la habilidad de la red para absorber dependencias a largo plazo en los datos, lo cual impacta de manera adversa en la exactitud de las predicciones en series con series con series con series con series con largas secuencias temporales.

2. ¿Cómo se aborda la estacionalidad en los datos de series temporales cuando se utilizan LSTM para realizar pronósticos y qué papel juega la diferenciación en el proceso?

Con la estacionalidad en los datos de series temporales se refiere a patrones repetitivos en intervalos regulares, como las fluctuaciones mensuales o anuales. Las LSTM, al no estar diseñadas únicamente para captar la estacionalidad de una manera explícita pueden no ser exactas a la hora de identificar y predecir los patrones. Una técnica común para manejar mejor la diferenciación es el restar el valor actual de un dato con su valor en un periodo anterior. Esto ayuda a eliminar los patrones estacionales antes de que estos entren al modelo, sin embargo el uso de la diferenciación en LSTM debe ser manejado con cuidado, ya que también puede introducir ruido, haciendo más difícil la predicción.

3. ¿Cuál es el concepto de "tamaño de ventana" en el pronóstico de series temporales con LSTM y cómo afecta la elección del tamaño de ventana a la capacidad del modelo para capturar patrones a corto y largo plazo?

Con el tamaño de ventana se refiere a la cantidad de pasos de tiempo anteriores que el modelo LSTM utiliza para hacer la predicción. Al elegir un tamaño de ventana pequeño, el modelo solo tiene en cuenta los patrones a corto plazo, lo que limita su capacidad para captar las tendencias más amplias de los datos. Un tamaño de ventana grande permite que

el modelo capte patrones a largo plazo, pero incrementa la complejidad del modelo y puede generar problemas como el overfitting si no hay suficiente información útil en esos pasos adicionales. La elección adecuada del tamaño es importante para equilibrar la capacidad del modelo, ya que con esto podrá predecir los patrones a largo y corto plazo.